

# Modelado Predictivo de Biomasa en Escama Marina de Jalisco

C. A. Amezcua López

Supervisado por: Mariana Salado Mejía, Gustavo Montes Cabrera

CUGDL - Lic. en Inteligencia Artificial y Ciencia de los Datos

## Resumen

Este estudio evalúa el desempeño de **Random Forest**, **SVM** y **Regresión Polinomial** en la pesquería de escama marina de Jalisco (2010–2021), con el objetivo de predecir biomasa e identificar determinantes de captura. El *Random Forest* resultó ser el modelo óptimo, explicando el **84 %** de la variabilidad. Asimismo, la transformación logarítmica refinó las métricas de evaluación en la mayoría de los modelos, validando indicadores clave de esfuerzo.

## Introducción

La pesquería de escama marina en Jalisco representa un pilar fundamental para la seguridad alimentaria y el desarrollo económico regional. No obstante, la gestión sostenible de este recurso enfrenta un desafío crítico: la **alta variabilidad biológica** combinada con inconsistencias severas y ruido en los registros históricos de captura.

Frente a la limitación de los métodos tradicionales para manejar datos imperfectos, este estudio propone un enfoque basado en **Ciencia de Datos**. A través de una auditoría y limpieza exhaustiva de la información cruda, se implementan modelos de *Machine Learning* capaces de aprender patrones complejos, transformando registros administrativos ruidosos en estimaciones de biomasa fiables para la toma de decisiones.

## Metodología

### 1. Stack Tecnológico y Preprocesamiento

El análisis se ejecutó en **Python** utilizando **Pandas** y **NumPy** para manipulación, **Seaborn** para visualización y **Scikit-Learn** para modelado.

- **Volumen Inicial:** 52,789 registros de actividad pesquera (Jalisco, 2010–2021).
- **Auditoría Lógica:** Se detectó inconsistencia física (**Duracion** < **DiasEfectivos**) en el 53.82 % de la muestra.
- **Depuración:** Eliminación estructural de la variable **Duracion** y descarte de registros con esfuerzo nulo o variables constantes (varianza cero).

### 2. Ingeniería de Características (Feature Engineering)

- **Multicolinealidad (VIF):** Se detectó redundancia severa ( $VIF > 500$ ) entre pesos. Se definió **PesoVivoKg** como variable objetivo (*Target*).
- **Codificación y Escalado:** Aplicación de *One-Hot Encoding* (agrupando categorías poco frecuentes en "OTROS") y normalización de magnitudes mediante **StandardScaler** para evitar sesgos numéricos.
- **Dataset Final:**  $\approx 15,464$  registros de alta calidad para entrenamiento.

### 3. Selección y Justificación de Modelos

Se seleccionaron tres arquitecturas distintas para abordar la complejidad de los datos pesqueros desde diferentes enfoques matemáticos:

| Modelo                  | Justificación de Selección                                                                                                                                                          |
|-------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Random Forest Regressor | <b>Ensamble no paramétrico.</b> Elegido por su robustez ante <i>outliers</i> y capacidad para capturar relaciones no lineales complejas típicas en biología sin sobreajuste severo. |
| Regresión Polinómica    | <b>Enfoque Curvilíneo.</b> Implementada (Grado 2) para modelar tendencias de crecimiento y saturación que una línea recta no puede captar.                                          |
| SVM (SVR)               | <b>Vectores de Soporte.</b> Seleccionado por su eficacia matemática para manejar la alta dimensionalidad generada tras la codificación de variables categóricas.                    |

### 4. Evaluación y Resultados

- **Métricas:** Se comparó el desempeño usando  $R^2$  y RMSE.
- **Ganador:** El **Random Forest** presentó el mejor ajuste ( $R^2 \approx 0,8187$ ,  $RMSE \approx 1469$  Kg), demostrando superioridad en generalización frente a los modelos paramétricos.

## Resultados

La evaluación comparativa expuso las capacidades y limitaciones de cada algoritmo. Sin embargo, el *Random Forest* demostró una superioridad indiscutible, manteniendo un rendimiento consistente y robusto tanto con datos originales como transformados logarítmicamente, consolidándose claramente como la opción más eficiente frente a las otras alternativas.




Fig. 1: Métricas de evaluación.

La transformación logarítmica generó efectos dispares. Si bien el Random Forest reafirmó su posición como el modelo superior, esta técnica fue clave para el SVM, elevando su  $R^2$  de 0.621 a 0.835. Por el contrario, afectó negativamente a la Regresión Polinomial, cuyo rendimiento cayó drásticamente de 0.761 a 0.322.




Fig. 2: Transformación logarítmica de la variable objetivo.

El análisis de variables independientes reveló una dualidad funcional. Mientras el modelo con datos originales priorizó la predicción de volúmenes totales (inventarios), la versión logarítmica ofreció una perspectiva distinta. Esta última captó con mayor fidelidad la dinámica biológica y el esfuerzo pesquero subyacente, al mitigar el sesgo provocado por las magnitudes extremas.

| Ranking | Variable (RF Normal)                              | Peso (Normal) | Variable (RF Log)                                   | Peso (Log) |
|---------|---------------------------------------------------|---------------|-----------------------------------------------------|------------|
| 1       | DiasEfectivos                                     | 53.4%         | DiasEfectivos                                       | 49.4%      |
| 2       | NombreSitioDesembarque_LAGUNA DE BARRA DE NAVIDAD | 14.4%         | NumeroEmbarcaciones                                 | 8.5%       |
| 3       | Precio                                            | 6.7%          | Anho                                                | 6.2%       |
| 4       | NumeroEmbarcaciones                               | 6.6%          | Precio                                              | 5.6%       |
| 5       | NombreSitioDesembarque_OTROS                      | 4.2%          | Mes                                                 | 4.3%       |
| 6       | Mes                                               | 3.5%          | NombreSitioDesembarque_LAGUNA DE BARRA DE NAVIDAD   | 3.0%       |
| 7       | Anho                                              | 3.1%          | NombrePrincipal_GUACHINANGO                         | 1.3%       |
| 8       | NombrePrincipal_MOJARRA                           | 1.2%          | NombreSitioDesembarque_DESEMBARCADERO LA MANZANILLA | 1.2%       |

Fig. 3: Top de variables independientes indicadoras.

## Discusión

Los resultados establecen una dicotomía clara en la utilidad de los modelos:

- **Predicción de Volumen (Escala Original):** El **Random Forest** sin transformar demostró ser superior para estimar inventarios y capturas totales, ya que su función de costos penaliza más los errores en grandes volúmenes, crucial para la gestión pesquera comercial.
- **Dinámica del Esfuerzo (Escala Logarítmica):** La aplicación de  $\log(y)$  fue determinante para la **explicabilidad**. Al amortiguar el sesgo de los valores atípicos (*outliers*), el modelo reveló que el **NumeroEmbarcaciones** y los **DiasEfectivos** son los verdaderos motores de la captura, validando la relación biológica entre esfuerzo y biomasa que permanecía oculta por el ruido en los datos crudos.

## Conclusión y Trabajo Futuro

El modelo *Random Forest* logró predecir las capturas con gran efectividad ( $R^2 \approx 0,82$ ), confirmando que es posible entender la dinámica pesquera con la información actual. Sin embargo, estas estimaciones reflejan solo el mínimo probable de la producción real, ya que los registros originales sufren de imprecisiones importantes.

El análisis reveló que muchas cooperativas reportan menos captura de la verdadera, ya sea por un temor injustificado a impuestos o por descuido al llenar las bitácoras. Por ello, el siguiente paso indispensable es implementar herramientas que detecten automáticamente estos datos sospechosos. Esto permitirá limpiar los errores humanos y calcular la verdadera abundancia del recurso, separando la realidad biológica de las fallas administrativas.